

SO SÁNH THỰC CHIẾN: AIRFLOW vs DAGSTER

Chuyên đề: Xử lý Hồ sơ Hóa đơn Đa trang (Invoice PDF Processing) & Chuyển dịch On-Premise

APACHE AIRFLOW

Workflow as Code (Task-Centric)

- Hệ sinh thái 10+ năm, chuẩn mực công nghiệp
- Điều phối tác vụ định kỳ & tích hợp hạ tầng
- KubernetesExecutor, Celery, RBAC chặt chẽ
- Hàng trăm nhà cung cấp dịch vụ (Providers)

VS

DAGSTER

Data as Code (Asset-Centric)

- Tách rời Code Server gRPC & Orchestrator
- Tích hợp kiểm định dữ liệu (Asset Checks)
- Kiểm thử in-memory siêu tốc trong CI/CD (~0.12s)
- Tự động truy vết Data Lineage & I/O Manager

AWS Step Functions & Thách Thức Chuyển Đổi

Đánh giá hiện trạng hạ tầng Cloud hiện tại và động lực di chuyển On-Premise

LỢI THẾ HIỆN TẠI (PROS)

- **Hoàn toàn Serverless:**

Không tốn công vận hành hạ tầng máy chủ hay cụm cluster.

- **Auto-Scaling tự động:**

Tự động scale theo tải khi có hàng nghìn request đổ về.

- **Pay-as-you-go:**

Chỉ trả phí dựa trên số lượng request và chuyển trạng thái thực tế.

- **Tích hợp sâu hệ sinh thái AWS:**

Kết nối trực tiếp Lambda, S3, DynamoDB, SQS mượt mà.

HẠN CHẾ & RỦI RO (CONS)

- **Khó khăn khi Test & Debug Local:**

Mô phỏng Step Function ở local rất phức tạp, chu kỳ phản hồi phát triển chậm.

- **Chi phí tăng vọt khi Scale tải lớn:**

Chi phí state transition rất đắt đỏ khi xử lý hàng triệu hóa đơn/tháng.

- **Rủi ro Vendor Lock-in:**

Bị ràng buộc mã nguồn vào dịch vụ AWS, khó chuyển sang Cloud khác.

- **Tuân thủ On-Premise & Bảo mật:**

Khách hàng tài chính/ngân hàng yêu cầu dữ liệu nhạy cảm phải xử lý nội bộ.

Bài Toán Tự Động Bóc Tách & Duyệt Hóa Đơn

Nghiệp vụ 4 loại hóa đơn & Luồng kiểm toán tài chính (PDF -> Data)

QUY TRÌNH NGHIỆP VỤ & KIỂM TOÁN

1. Phân loại 4 trang hóa đơn (4 Types):


- Trang 1 (VAT): Lấy MST, Tiền hàng, Tiền thuế GTGT 10%.
- Trang 2 (Utility): Lấy Customer ID đối chiếu tiền điện/nước.
- Trang 3 (Travel): Lấy Employee ID để hoàn ứng công tác.
- Trang 4 (Retail): Gắn cờ cảnh báo: Không duyệt khấu trừ thuế!

2. Tiêu chuẩn kiểm toán (Validation Rules):

- Số học: Tiền hàng + Tiền thuế có khớp Tổng tiền không?
- Hạn mức: Tổng tiền toàn bộ hóa đơn có vượt 100M VNĐ không?



3. Kết quả phê duyệt (Approval):

- Đạt chuẩn: Duyệt & Lưu vào Database / Ledger.
- Lỗi / Vượt hạn mức: Dừng ngay lập tức (Hard Stop)!



Đối Chiếu Kiến Trúc: Task-Centric vs Asset-Centric

Chuỗi hành động thực thi (Airflow Tasks) vs Mạng lưới tài sản dữ liệu (Dagster Assets)



Vòng Đời Thực Thi 1 Task Trong Apache Airflow

Chu trình thực thi 6 bước & Các điểm nghẽn kiến trúc (DAG Parsing Loop, DB Hits, XCom DB)

AIRFLOW TASK EXECUTION (Chu Trình 6 Bước)

1. Write Code File

(dags/invoice_dag.py)



2. DAG Parsing Loop (Mỗi 30 Giây)

(Scheduler re-compiles Python from disk - CPU Overhead)



3. Task State Transitions (DB Hits)

[NONE] → [SCHEDULED] → [QUEUED] → UPDATE task_instance



4. Worker Pulls & Runs Task

(State: [RUNNING] trên Celery Worker / K8s Pod)



5. Data Exchange via XCom DB

INSERT INTO xcom VALUES (...) (JSON/Pickle Payloads in Postgres)



6. Webserver DB Polling

SELECT state → Tô màu ô Xanh/Đỏ (⚠ MÙ DỮ LIỆU)

1. Bị Ép Re-Parse Liên Tục (30s/lần)

Scheduler không lưu cấu trúc trên RAM mà liên tục đọc và biên dịch lại code Python. Lỗi import OCR nặng ngoài hàm → Treo 100% CPU toàn cụm.

2. State Machine Bắn Query DB Dồn Dập

Mỗi bước chuyển trạng thái (None → Scheduled → Queued → Running → Success) đều UPDATE Postgres → Nguy cơ lock bằng khi tải lớn.

3. Ép Nạp Dữ Liệu XCom Thẳng Vào Postgres

Khi task return, Airflow serialize rồi INSERT INTO xcom. Dữ liệu lớn (ảnh hóa đơn, DataFrame) làm phình to DB và nghẽn I/O hệ thống.

4. Kết Thúc Bằng 'Mù Dữ Liệu' Trên UI

Webserver chỉ đọc DB để tô màu ô vuông Xanh/Đỏ. Kỹ sư hoàn toàn không biết bên trong có bao nhiêu tiền, bao nhiêu hóa đơn nếu không mở log.

Kiến Trúc Điều Phối Hiện Đại Trong Dagster

Chu trình phân tách 6 bước (gRPC Code Server, Ephemeral Worker, I/O Manager, Khiên Asset Checks)

DAGSTER ASSET MATERIALIZATION (Chu Trình Phân Tách)

1. User Code Server (Isolated Process)

assets.py với các hàm pure Python trong môi trường độc lập



2. gRPC Discovery (Zero Scheduler Load)

Gửi Asset Schema & Lineage qua gRPC - Không bao giờ parse định kỳ



3. Trigger & Run Execution Plan

Sensor / Schedule / UI Materialize → Bắn Event log vào DB



4. Launch Ephemeral Worker

Khởi động Pod/Container độc lập để thực thi tính toán Asset



5A. I/O Manager & 5B. Asset Checks

Payloads đẩy thẳng S3/MinIO | @asset_check(blocking=True) kiểm toán tại chỗ



6. Real-time Event Log & UI Lineage

Hiện giá trị tiền, số lượng hóa đơn trực quan ngay trên Dashboard

1. Khám Phá Metadata Qua gRPC (Zero Load)

Code người dùng chạy trong tiến trình riêng. Nền tảng chỉ dùng gRPC để hỏi schema và lineage, hoàn toàn không nạp code Python của user vào Scheduler.

2. Chạy Trong Worker Độc Lập (Ephemeral)

Mỗi lần chạy bật một container/pod độc lập thực thi hàm Asset thuần khiết. Code có crash hay OOM thì Daemon và Webserver vẫn an toàn 100%.

3. I/O Manager Độc Lập & Không Đụng DB

Dữ liệu trả về được I/O Manager tự động đẩy thẳng lên S3/MinIO hoặc Snowflake. Database hệ thống chỉ lưu nhật ký sự kiện, không lo phình bộ nhớ.

4. Asset Checks Đánh Chặn & Báo Cáo Trên UI

Kiểm định chất lượng dữ liệu được gắn trực tiếp vào Asset. Nếu vi phạm trần 100M sẽ chặn downstream ngay và cảnh báo trên giao diện.

Hạ Tầng On-Premise & Năng Lực Kiểm Thử CI/CD

Kiến trúc cụm On-Prem (Kubernetes, MinIO, PostgreSQL) và Tốc độ kiểm thử tự động

HẠ TẦNG ON-PREMISE (K8S & STORAGE)

- **Kubernetes Cluster:**

Triển khai điều phối bằng Helm Charts chính thức của Airflow / Dagster.

- **MinIO (Object Storage S3-Compatible):**

Thay thế hoàn hảo AWS S3 để lưu trữ file PDF hóa đơn và artifacts.

- **PostgreSQL HA:**

Lưu trữ metadata của hệ thống với cụm replica độ tin cậy cao.

- **Vault & Keycloak:**

Quản lý secret và xác thực bảo mật tập trung cho toàn bộ dịch vụ.

TỐC ĐỘ KIỂM THỬ CI/CD & DEVELOPER UX

- **Airflow Unit Test (Phức tạp, 5-15 giây):**

Cần khởi tạo SQLite database giả lập, mock context và task instance. Chạy chậm trong CI.

- **Dagster In-Memory Test (Cực nhanh, ~0.12 giây):**

Hỗ trợ materialize([asset_name]) trực tiếp trong RAM, không cần database hay server. Tích hợp trơn tru vào Pytest.

- **Tự tin Refactor:**

Kỹ sư tự do thay đổi logic xử lý hóa đơn và kiểm tra ngay lập tức tại máy cá nhân.

- **Tối ưu chu kỳ phản hồi:**

Rút ngắn thời gian phát hiện lỗi từ hàng phút xuống chỉ vài trăm mili-giây.

Ma Trận So Sánh Kỹ Thuật Tổng Hợp

Đánh giá 7 tiêu chí so sánh toàn diện giữa Apache Airflow và Dagster

Tiêu Chí	Apache Airflow	Dagster	Thắng
Mô hình cốt lõi	Task-Centric (Workflow as Code)	Asset-Centric (Data as Code)	Dagster
Quản lý Dữ liệu	XCom qua Database (Dễ nghẽn)	I/O Manager tự động (S3/MinIO)	Dagster
Kiểm định Dữ liệu	Tự viết Task/Sensor kiểm tra	Asset Checks 1st-class tích hợp	Dagster
Kiểm thử Local & CI	Mock phức tạp, khởi tạo DB chậm	In-Memory Test cực nhanh (0.12s)	Dagster
Độ chín & Cộng đồng	10+ năm, tài liệu & provider khổng lồ	Mới hơn, cộng đồng đang tăng trưởng	Airflow
Bảo mật & Phân quyền	RBAC hoàn thiện, hỗ trợ LDAP/OAuth	RBAC chủ yếu trên Dagster Cloud	Airflow
Điều phối Đa nhiệm	Mạnh về Job hạ tầng / DevOps / Spark	Mạnh về Modern Data Platform & AI/ML	Hòa

Định Vị Giải Pháp: Tiêu Chí Lựa Chọn Airflow vs Dagster

Căn cứ lựa chọn công nghệ phù hợp với đặc thù dự án và bài toán của doanh nghiệp

NÊN CHỌN AIRFLOW KHI:

- **Team đã có kinh nghiệm Airflow dày dặn:**
Tận dụng hạ tầng, kỹ năng và quy trình DevOps sẵn có.
- **Bài toán điều phối hạ tầng (Orchestration):**
Kích hoạt định kỳ các tác vụ dbt, EMR, Kubernetes Job, backup DB.
- **Hệ thống yêu cầu RBAC khắt khe On-Premise:**
Cần phân quyền truy cập DAG chi tiết cho từng người dùng/nhóm.
- **Ít quan tâm đến Data Lineage & Asset Quality:**
Quy trình ETL đơn giản, chuyển dữ liệu từ A sang B định kỳ.
- **Cần sự ổn định lâu dài:**
Thư viện plugin phong phú hỗ trợ gần như mọi dịch vụ công nghệ trên thị trường.

NÊN CHỌN DAGSTER KHI:

- **Xây dựng Modern Data Platform / Data Mesh:**
Nơi tài sản dữ liệu, chất lượng dữ liệu và Data Catalog là ưu tiên hàng đầu.
- **Tập trung vào Tự động hóa Kiểm thử (Testing):**
Muốn kiểm thử toàn bộ pipeline trong CI/CD trước khi đưa lên production.
- **Pipeline xử lý dữ liệu phức tạp & AI/ML:**
Cần theo dõi Data Lineage, phân nhánh theo chất lượng dữ liệu như bài toán hóa đơn.
- **Môi trường phát triển đa đội ngũ:**
Nhiều team cùng phát triển trên các Code Server cô lập, không ảnh hưởng lẫn nhau.
- **Muốn trải nghiệm phát triển (DevX) vượt trội:**
Giao diện hiện đại, trực quan, hỗ trợ reload code chỉ với một cú click.

Lộ Trình Triển Khai Chuyển Đổi 3 Giai Đoạn

Chiến lược chuyển đổi khả thi giúp giảm thiểu rủi ro gián đoạn hệ thống

GIAI ĐOẠN 1 (Tháng 1-2) **THỬ NGHIỆM (POC)**

- Triển khai cụm thử nghiệm (Local / Dev K8s).
- Chạy song song kịch bản xử lý Invoice PDF trên cả 2 công cụ.
- Đo lường thời gian test CI/CD và độ ổn định khi tải tăng.
- Thu thập đánh giá trải nghiệm thực tế từ các kỹ sư dữ liệu.

GIAI ĐOẠN 2 (Tháng 3-4) **HYBRID CO-EXISTENCE**

- Tận dụng Airflow điều phối các tác vụ hạ tầng và hệ thống cũ.
- Sử dụng Dagster cho các pipeline bóc tách dữ liệu mới và AI/ML.
- Đồng bộ hóa lưu trữ artifacts qua MinIO On-Premise chung.
- Xây dựng bộ quy chuẩn CI/CD và tiêu chuẩn viết Asset Checks.

GIAI ĐOẠN 3 (Tháng 5+) **CHUYỂN DỊCH HOÀN TOÀN**

- Di chuyển toàn bộ pipeline nghiệp vụ quan trọng sang nền tảng chuẩn hóa.
- Hoàn thiện hệ thống giám sát cảnh báo (Prometheus, Grafana).
- Đóng gói tài liệu bàn giao, đào tạo nội bộ và tối ưu hóa chi phí On-Prem.
- Tự tin mở rộng quy mô xử lý hàng triệu hóa đơn/tháng.

Tổng Kết & Thảo Luận (Q&A)

Thông điệp cốt lõi và sẵn sàng giải đáp thắc mắc chuyên sâu

1. Không có công cụ 'hoàn hảo nhất', chỉ có công cụ 'phù hợp nhất':

Airflow vững chãi cho điều phối hạ tầng truyền thống; Dagster vượt trội cho kỹ thuật dữ liệu hiện đại và kiểm soát chất lượng.

2. Asset-Centric là tương lai của Quản trị Dữ liệu:

Tư duy lấy dữ liệu làm trung tâm giúp doanh nghiệp kiểm soát tính toàn vẹn, data lineage và sẵn sàng cho các bài toán AI/LLM.

3. Tự chủ On-Premise tối ưu chi phí và bảo mật:

Kết hợp Kubernetes và MinIO giúp doanh nghiệp kiểm soát 100% dữ liệu nhạy cảm mà không bị phụ thuộc vào hóa đơn điện toán đám mây.

SẴN SÀNG TRẢ LỜI CÂU HỎI (Q&A)

Xin chân thành cảm ơn quý anh chị đã lắng nghe!